

# Kairos 三位审稿人问题总结与最小修改方案

## 0. 论文核心内容

这篇论文提出 **Kairos**，一个显式 temporal reasoning 框架。它关注的不是普通 QA 里模型是否答对，而是：

模型在原问题上答对了，不代表它真的理解事件顺序；如果我们反事实地改变事件发生顺序，模型是否能同步更新 temporal relation 和最终答案？

Kairos 的流程大概是：

1. 从输入中抽取事件。
2. 把每个事件映射成一个 **latent interval**，也就是隐式的 start / end 时间区间。
3. 根据这些 interval 预测事件之间的 temporal relation，例如 before、after、overlap、during。
4. 构建 event-relation graph。
5. 用这个 graph 去 rerank candidate answers。
6. 通过 counterfactual temporal supervision 训练模型，让模型在事件顺序被改变后，能更新 temporal relation 和最终答案。

这篇论文最应该强调的 claim 是：

Kairos 主要提升的是 counterfactual event-order shift 下的 temporal consistency，而不是泛泛地宣称自己是 general temporal reasoning SOTA。

---

## 1. Reviewer hKcH

### 评分情况

- Overall Assessment: **2.5 = Borderline Findings**
- Soundness: **3**
- Excitement: **3**
- Confidence: **3**

### 正面评价

Reviewer 原文：

The motivation and task framing are well motivated and interesting.

中文理解：

这个 reviewer 认可问题动机和任务设定。TA 不是觉得 idea 不行，而是觉得实验支撑还不够。

### 主要问题

Reviewer 原文：

Evaluation uses custom subsets rather than established temporal datasets.

The baselines are limited and do not include structured temporal-reasoning, temporal-relation extraction, or interval/constraint-based methods.

The comparison is somewhat asymmetric because Kairos uses supervised and counterfactual training, while the baselines are prompting-only.

Add stronger temporal baselines and temporal benchmarks or justify their omission.

对应中文总结：

1. 现在主要用自建 temporal subsets，而不是标准 temporal reasoning benchmark。
2. baseline 太弱，只和 Direct Prompting、CoT、Self-Consistency、CoT+Verifier 这类 prompting baseline 比。
3. Kairos 用了 supervised training 和 counterfactual training，但 baseline 是 prompt-only，所以比较不完全公平。
4. 需要补 stronger temporal baselines 和 temporal benchmarks，或者解释为什么没有补。

## 对应修改方式

### 修改 1：补标准 temporal benchmark

建议最小补充：

- **TORQUE**

作用：

- 回应“只在自建 subset 上评测”的问题。
- 说明 Kairos 不只是对 GSM8K / MuSiQue / StrategyQA / 2Wiki 中抽出来的 temporal subset 有效。

Rebuttal 里可以说：

我们同意标准 temporal benchmark 很重要。当前自建 subsets 的目的是构造可控的 counterfactual order-shift evaluation，用来测模型是否在事件顺序变化后更新 temporal relation 和 answer。我们会补充 TORQUE，并在论文中明确当前数据集的定位是 controlled counterfactual temporal consistency benchmark，而不是 general temporal QA benchmark 的替代品。

### 修改 2：补 stronger baseline

最小补两个：

#### 2.1 Same-data SFT baseline

做法：

- 用和 Kairos 完全相同的 counterfactual training data。
- 训练一个普通 SFT model。
- 不加 interval projection。

- 不加 event-relation graph。
- 不加 graph-aware reranking。
- 不加 relation module。

目的：

- 证明 Kairos 的提升不是因为用了更多监督数据，而是因为 interval / graph 结构确实有用。

## 2.2 LLM-Graph baseline

做法：

- 让 LLM 先抽取事件。
- 再预测 pairwise temporal relation。
- 构建 temporal graph。
- 再基于 graph 回答或 rerank。

目的：

- 回应“缺少 structured temporal reasoning baseline”的问题。
- 这个 baseline 比普通 CoT 更接近 Kairos。

Rebuttal 里可以说：

我们会补充 stronger structured baselines，包括 same-supervision SFT baseline 和 LLM-generated temporal graph baseline。这两个 baseline 可以更直接地验证 Kairos 的提升是否来自显式 interval / graph temporal representation。

## 修改 3：澄清比较不完全公平

不要硬说 Kairos 和 prompting baselines 完全公平。应该承认：

- Kairos 是 trained structured model。
- Direct / CoT / Self-Consistency 是 prompt-only baselines。
- 这两类方法的比较目的不同。

Rebuttal 里可以说：

我们同意 Kairos 不是 prompt-only 方法。我们会在修改版中明确区分 prompt-only LLM baselines、same-supervision trained baselines 和 Kairos structured model。我们不会把 prompt-only comparison 表述成完全公平的同设定比较，而是用它展示 prompt-only 方法在 counterfactual temporal shift 下的局限。

# 2. Reviewer h2iV

## 评分情况

- Overall Assessment: **1.5 = Resubmit after next cycle**
- Soundness: **1.5**
- Excitement: **1.5**

- Confidence: 5

## 正面评价

Reviewer 原文：

Interval representation is intuitive. Modeling events with latent start and end coordinates is conceptually aligned with temporal relations such as before, after, overlap, and containment.

中文理解：

这是最负面的 reviewer，但 TA 仍然认可 interval representation 的直觉合理性。主要问题不是核心想法完全不成立，而是觉得论文实验和写作都不够成熟。

## 主要问题

Reviewer 原文：

The evaluation datasets are not standard temporal reasoning benchmarks.

The baselines are weak and outdated. The main baselines are direct prompting, CoT, self-consistency, and CoT+Verifier, which are relatively simple 2022–2023 prompting methods.

The temporal subset construction is under-specified.

The paper feels underdeveloped. The submission does not use the full 8-page space, and several important details are missing or only briefly discussed. More space could have been used to explain the data construction, baselines, implementation details, and error analysis.

对应中文总结：

1. 数据集不是标准 temporal reasoning benchmark。
2. baseline 弱且旧。
3. temporal subset 构造过程没有讲清楚。
4. 论文显得 underdeveloped，没有用满篇幅，很多关键细节缺失。

## 对应修改方式

### 修改 1：补 TORQUE

这是最直接回应 h2iV 的方式。

最小修改：

- 加一个标准 temporal benchmark: **TORQUE**。
- 如果来不及补完整实验，至少在 rebuttal 中明确承诺会加入。
- 但最好能真的补出结果。

Rebuttal 里可以说：

我们同意 dedicated temporal reasoning benchmark 对验证泛化性很重要。我们会加入 TORQUE 作为标准 temporal ordering QA benchmark，并把当前自建 subsets 明确定位为 controlled counterfactual probes。

## 修改 2：补 stronger baseline

h2iv 对 baseline 的批评最重，所以至少要补：

1. **Same-data SFT baseline**
2. **LLM-Graph baseline**

如果还有时间，可以加：

1. **Rule-Graph / Constraint-Rerank baseline**

Rule-Graph 做法：

- 用 before / after / during / while / then 等显式 marker 抽 temporal relation。
- 构造 rule-based temporal graph。
- 用 temporal constraint 去 rerank answers。

作用：

- 检查 Kairos 是否只是学到了简单 marker 规则。
- 如果 Kairos 明显强于 Rule-Graph，就能说明 interval / graph learned representation 有贡献。

## 修改 3：补 dataset construction statistics table

这是最便宜但最重要的修改之一。

建议新增一个表：

| Dataset             | Raw examples | Temporal filtered | Event extraction success | Reliable relation labels | Valid counterfactuals | Final retained |
|---------------------|--------------|-------------------|--------------------------|--------------------------|-----------------------|----------------|
| GSM8K-temporal      | TBD          | TBD               | TBD                      | TBD                      | TBD                   | TBD            |
| MuSiQue-temporal    | TBD          | TBD               | TBD                      | TBD                      | TBD                   | TBD            |
| StrategyQA-temporal | TBD          | TBD               | TBD                      | TBD                      | TBD                   | TBD            |
| 2Wiki-temporal      | TBD          | TBD               | TBD                      | TBD                      | TBD                   | TBD            |

还需要补充说明：

- temporal examples 怎么筛选；

- temporal marker list 是什么；
- event extraction 怎么做；
- relation labels 怎么判断可靠；
- counterfactual perturbation 怎么生成；
- answer flip 怎么验证；
- 删除了多少样本；
- 典型删除样例是什么；
- 是否有人类检查，检查比例是多少。

Rebuttal 里可以说：

我们同意当前版本对 subset construction 说明不足。修改版会加入完整的数据构造流程表，包括 raw examples、filtered examples、event extraction success、reliable relation labels、valid counterfactuals 和 final retained examples，并补充 retained / removed examples。

#### 修改 4：把未用篇幅补到关键细节上

h2iv 认为论文 underdeveloped，所以修改版主文中应该补：

- 数据构造细节；
- stronger baselines；
- implementation details；
- error analysis；
- latent interval visualization；
- counterfactual construction examples。

Rebuttal 里可以说：

我们会使用主文中未充分利用的篇幅，扩展 dataset construction、baseline design、implementation details 和 qualitative error analysis，而不是只把细节放到 appendix。

## 3. Reviewer Cjps

### 评分情况

- Overall Assessment: **3 = Findings**
- Soundness: **3**
- Excitement: **3**
- Confidence: **4**

### 正面评价

Reviewer 原文：

The problem is interesting and relevant. I agree with the paper's motivation that final answer accuracy does not always mean the model really understands event order.

The counterfactual order-shift setting is a useful way to test this problem.

The idea of representing events as latent intervals is intuitive.

The framework is clear overall.

The paper evaluates both final answer accuracy and relation-level behavior.

The ablation study is useful.

The held-out template and second-backbone results are helpful. They show that the improvement is not only from memorizing the exact training perturbation templates.

中文理解：

这是最正面的 reviewer。TA 认可：

1. 问题重要；
2. counterfactual order-shift setting 有意义；
3. latent interval 表达直觉合理；
4. 框架清晰；
5. 同时评估 answer accuracy 和 relation-level behavior 是优点；
6. ablation 有用；
7. held-out template 和 second-backbone 能说明不是单纯记模板。

这位 reviewer 应该重点稳住。

## 主要问题

Reviewer 原文：

The dataset construction is still quite artificial.

The event and relation extraction pipeline may be too simple.

The method relies on event mentions and reliable temporal markers such as before, after, during, while, and then.

The counterfactual perturbations may introduce annotation artifacts.

The comparison baselines are not very strong.

The method adds extra supervision and uses gold answer candidates during training for open-ended tasks. This makes the comparison with prompting-based baselines a little hard to interpret.

The gains are consistent but not very large in some settings.

The interval representation is elegant, but it is not clear whether the learned start and end coordinates are really interpretable.

The evaluation focuses on short or controlled examples.

The paper would benefit from more qualitative error analysis.

对应中文总结：

1. 数据构造偏人工，依赖规则和模板。
2. event / relation extraction pipeline 可能太简单。
3. 方法可能依赖 explicit temporal markers。
4. counterfactual perturbation 可能引入 annotation artifact。
5. baseline 不够强。
6. Kairos 用了额外监督和 gold answer candidates，和 prompting baselines 比较不清楚。
7. 一些 setting 下 gain 不大。
8. latent interval 是否真的可解释还不清楚。
9. 评估主要是短文本、受控样例，不知道长文档、多事件、复杂 timeline 表现如何。
10. 缺少 qualitative error analysis。

## 对应修改方式

### 修改 1：补 explicit-marker vs implicit-relation split

目的：

- 回应“方法可能只依赖 before / after / during / while / then 这些显式 marker”。

做法：

把测试集分成两类：

| Split                  | 说明                                                   | 目的                             |
|------------------------|------------------------------------------------------|--------------------------------|
| Explicit-marker        | 有 before、after、during、while、then 等显式 temporal marker | 测明确时间线索下的表现                    |
| Implicit / weak-marker | 没有明显 marker，需要从上下文推断 temporal relation               | 测是否能泛化到更真实的 temporal reasoning |

Rebuttal 里可以说：

我们同意 marker-based relation labels 是当前方法的一个限制。我们会新增 explicit-marker vs implicit-relation 分析，明确 Kairos 在显式 temporal cues 和隐式 temporal relations 下的表现差异。

### 修改 2：补 template artifact test

Cjps 认可 held-out template 有帮助，但仍担心模板 artifact。

最小可补：

- paraphrased perturbations;
- answer-unchanged distractors。

其中 answer-unchanged distractor 很有用。

例子：

原始句子：A happened before B. Question asks about C.  
扰动句子：A happened after B. Question still asks about C.  
正确答案不应该变化。

目的：

- 检查模型是否只要看到 before / after 被替换就盲目改变答案。

Rebuttal 里可以说：

我们已有 held-out template evaluation，说明模型不是简单记忆训练模板。修改版会进一步加入 paraphrased perturbations 或 answer-unchanged distractors，检查模型是否会在无关 temporal marker 改变时错误翻转答案。

### 修改 3：补公平性 baseline

同样是：

1. Same-data SFT baseline;
2. LLM-Graph baseline。

作用：

- 证明不是因为 Kairos 用了额外监督才赢。
- 证明不是只和弱 prompting baseline 比。

### 修改 4：收窄 claim，不要过度强调 general QA gain

Reviewer 说有些 setting 下 gain 不大，比如 standard GSM8K 上相比 self-consistency 提升有限。

所以修改时不要说：

Kairos broadly improves general QA accuracy.

应该说：

Kairos 的主要收益体现在 counterfactual temporal shift 下的 robustness 和 relation-level update accuracy。

Rebuttal 里可以说：

我们会修改表述，强调 Kairos 的主要贡献是提升 counterfactual temporal shifts 下的 answer robustness 和 relation-level consistency，而不是宣称在所有标准 QA setting 上都有大幅提升。

## 修改 5：补 latent interval visualization

Cjps 明确要求分析 learned start/end coordinates 是否 meaningful。

建议补 2-3 个 case studies。

例子：

Original:  
A happened before B, and B overlapped with C.

Learned latent intervals:  
A: [0.12, 0.25]  
B: [0.36, 0.61]  
C: [0.48, 0.75]

Predicted relations:  
A before B  
B overlaps C  
A before C

再展示 counterfactual 之后：

Counterfactual:  
B happened before A.

Updated intervals:  
B: [0.10, 0.22]  
A: [0.35, 0.50]  
C: [0.48, 0.75]

目的：

- 让 latent interval 不只是一个抽象模块，而是看起来真的对应了合理 temporal structure。

## 修改 6：补 failure cases

至少补 3-4 类 failure：

| Error type               | 说明                                     |
|--------------------------|----------------------------------------|
| Event extraction error   | 事件边界抽错，或者漏掉事件                          |
| Implicit relation missed | 没有显式 marker，模型没推出来 temporal relation   |
| Wrong answer update      | relation graph 更新对了，但 final answer 没更新 |
| Spurious template flip   | marker 改了，但问题答案本不该变，模型却错误翻转答案          |
| Long-context confusion   | 多事件或长上下文导致 graph 混乱                    |

Rebuttal 里可以说：

我们会加入代表性 failure cases，展示 Kairos 当前主要失败在 event extraction、implicit temporal relation、answer update grounding 和 long-context multi-event reasoning 上。

---

## 4. 最小修改清单

为了用最少工作覆盖三位 reviewer 的主要问题，建议只补以下 6 项。

### 1. Same-data SFT baseline

做法：

- 使用与 Kairos 相同的 counterfactual training data。
- 训练普通 SFT model。
- 不使用 interval projection、relation graph、graph-aware answer scoring。

解决问题：

- Kairos 和 prompt-only baseline 不公平。
- 提升可能只是来自额外监督数据。
- 需要 same-supervision baseline 来隔离结构模块贡献。

覆盖 reviewer：

- hKcH
  - h2iV
  - Cjps
- 

### 2. LLM-Graph baseline

做法：

- 让 LLM 抽取 event mentions。
- 预测 pairwise temporal relations。
- 构造 temporal graph。
- 基于 graph 回答或 rerank。

解决问题：

- baseline 太弱。
- 缺少 structured temporal reasoning baseline。
- 只和 Direct / CoT / Self-Consistency 比不够。

覆盖 reviewer：

- hKcH
- h2iV

- Cjps

---

### 3. TORQUE benchmark

做法：

- 在 TORQUE 上评估 Kairos。
- 至少报告 answer accuracy。
- 如果能做 relation-level evaluation，更好。

解决问题：

- 只用自建 temporal subsets。
- 缺少 standard temporal reasoning benchmark。
- 不确定是否泛化到 dedicated temporal reasoning data。

覆盖 reviewer：

- hKcH
- h2iV

---

### 4. Dataset construction statistics table

做法：

新增数据构造统计表：

| Dataset             | Raw examples | Temporal filtered | Event extraction success | Reliable relation labels | Valid counterfactuals | Final retained |
|---------------------|--------------|-------------------|--------------------------|--------------------------|-----------------------|----------------|
| GSM8K-temporal      | TBD          | TBD               | TBD                      | TBD                      | TBD                   | TBD            |
| MuSiQue-temporal    | TBD          | TBD               | TBD                      | TBD                      | TBD                   | TBD            |
| StrategyQA-temporal | TBD          | TBD               | TBD                      | TBD                      | TBD                   | TBD            |
| 2Wiki-temporal      | TBD          | TBD               | TBD                      | TBD                      | TBD                   | TBD            |

同时补充：

- filtering rules;
- temporal marker list;
- retained examples;
- removed examples;

- human checking ratio;
- counterfactual validity check。

解决问题：

- 数据构造 under-specified。
- 标注可靠性不清楚。
- 可复现性不足。
- 论文显得 underdeveloped。

覆盖 reviewer：

- h2iV
- Cjps
- hKcH

---

## 5. Explicit-marker vs implicit-relation analysis

做法：

把数据分成：

1. explicit-marker cases;
2. implicit / weak-marker cases。

分别报告：

- answer accuracy;
- relation accuracy;
- relation update accuracy;
- counterfactual consistency。

解决问题：

- 方法可能只依赖 before / after / during 等显式 marker。
- 数据过于人工。
- 不知道是否能处理真实文本中的隐式 temporal relation。

覆盖 reviewer：

- Cjps
- h2iV

---

## 6. Latent interval visualization + failure cases

做法：

补充：

1. 2-3 个 learned latent interval examples;
2. counterfactual 前后 relation graph 变化;
3. 3-4 个 failure cases。

解决问题：

- latent interval 是否真的 meaningful。
- 缺少 error analysis。
- 论文显得过于 compact / underdeveloped。

覆盖 reviewer：

- Cjps
- h2iV

---

## 5. Rebuttal 总体策略

不要把 rebuttal 写成 “审稿人误解了我们”。更好的策略是：

1. 承认当前版本有实验和写作不足。
2. 说明核心 idea 和 problem setting 仍然成立。
3. 把 claim 收窄到 counterfactual temporal consistency。
4. 用最小补充实验回应所有核心批评。

建议总回应：

We thank the reviewers for the constructive feedback. We agree that the current version under-explains dataset construction and lacks sufficiently strong structured temporal baselines. We will revise the paper to better clarify the scope of our claim: Kairos is designed to improve counterfactual temporal consistency under event-order shifts, rather than to claim general temporal QA SOTA.

中文意思：

感谢审稿人的建设性意见。我们同意当前版本对数据构造解释不够充分，也缺少足够强的 structured temporal baselines。我们会修改论文，进一步澄清本文 claim 的范围：Kairos 旨在提升 event-order shifts 下的 counterfactual temporal consistency，而不是宣称 general temporal QA SOTA。

然后接：

To address the concerns, we will add a same-supervision SFT baseline, an LLM-based temporal graph baseline, evaluation on TORQUE, detailed dataset construction statistics, explicit-marker versus implicit-relation analysis, and qualitative latent-interval visualizations with failure cases.

中文意思：

为回应这些问题，我们会补充 same-supervision SFT baseline、LLM-based temporal graph baseline、TORQUE benchmark、详细的数据构造统计、explicit-marker vs implicit-relation 分析，以及 latent interval 可视化和 failure cases。

---

## 6. 给合著者的最终结论

这篇 paper 不是 idea 被否定了，而是 reviewer 觉得当前版本实验和说明不够成熟。

三个 reviewer 共同关心的是：

1. 数据集不够标准；
2. baseline 不够强；
3. Kairos 和 prompt-only baseline 比较不公平；
4. 数据构造细节不足；
5. 方法可能依赖 marker / template artifact；
6. latent interval 的可解释性和 failure case 不够。

最小修改就做 6 件事：

1. **Same-data SFT baseline**
2. **LLM-Graph baseline**
3. **TORQUE benchmark**
4. **Dataset construction statistics table**
5. **Explicit-marker vs implicit-relation split**
6. **Latent interval visualization + failure cases**

修改后的定位应该是：

Kairos 是一个用于 counterfactual temporal consistency 的显式 temporal reasoning 框架，通过 latent interval、event-relation graph 和 counterfactual temporal supervision，让模型在事件顺序变化时更可靠地更新 temporal relation 和 final answer。

不要定位成：

Kairos 是一个 general temporal reasoning SOTA model。